IMAGE DENOISING · EUROSAT

Denoising di immagini satellitari EuroSAT: AutoEncoder vs VAE

Project work

Confronto tra autoencoder deterministico e variazionale sul dataset EuroSAT

Alessandro

Ottobre 2026

Obiettivo

- Ripristinare immagini satellitari degradate da rumore e sfocatura.
- Trattare il denoising come ricostruzione immagine-to-immagine: input degradato, target pulito.
- Confrontare un **AutoEncoder deterministico** e un **VAE** regolarizzato, a parità di budget.
- Misurare la qualità con MSE, PSNR e SSIM, sempre rispetto a una **baseline rumorosa**.

Domanda di ricerca

Il VAE è competitivo quanto l'AE quando il compito è il denoising, e a quali livelli di degrado conviene davvero applicare un modello?

Dataset EuroSAT

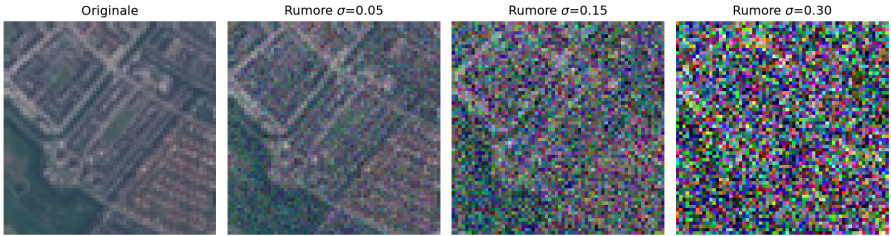
- 27.000 immagini RGB 64×64, 10 classi di uso del suolo.
- Split stratificato 70/15/15 con seed 42.
- Target: immagine pulita; input: versione degradata.
- Pixel normalizzati in $[0, 1]$.

Split	Immagini	%
Training	18.900	70
Validation	4.050	15
Test	4.050	15
Totale	27.000	100

La stratificazione preserva la proporzione delle classi in ogni partizione.

Il degrado

- Rumore gaussiano additivo: $\sigma \in \{0{,}05,\ 0{,}15,\ 0{,}30\}$.
- Blur gaussiano opzionale *prima* del rumore: $\sigma_b \in \{0{,}5,\ 1{,}0,\ 2{,}0\}$, kernel 5×5.
- 9 condizioni di degrado per modello; clip finale in $[0, 1]$.



Originale e tre livelli di rumore gaussiano ($\sigma = 0{,}05,\ 0{,}15,\ 0{,}30$).

Le due architetture

ConvAutoencoder

- Encoder $3 \to 32 \to 64$, stride 2.
- Latente di 64 dimensioni.
- Decoder con conv transpose e sigmoid.
- Mappa deterministica input $\to$ output.

ConvVAE

- Stesso encoder dell'AE.
- Teste μ e $\log \sigma^2$.
- Reparameterization: $z = \mu + \sigma \odot \varepsilon$.
- Valutazione con $z = \mu$.



L'AE è deterministico; il VAE modella uno spazio latente probabilistico.

Loss e protocollo

AutoEncoder

$$\mathcal{L}_{\mathrm{AE}} = \mathrm{MSE}(\hat{x}, x)$$

Nessuna regolarizzazione.

VAE

$$\mathcal{L}_{\mathrm{VAE}} = \mathrm{MSE}(\hat{x}, x) + \beta\,\mathrm{KL}(q(z|y)\,\|\,\mathcal{N}(0, I))$$

$\beta = 10^{-4}$, latente 64.

- 18 esperimenti: 3 livelli di rumore $\times$ 3 blur $\times$ 2 modelli.
- 5 epoche, batch 128, Adam con learning rate 10^{-3}.
- Early stopping con patience 3; checkpoint sul validation MSE.
- Rumore di validation e test generato con seed fissi.

Latente di 64 dimensioni e stesso budget di training per entrambi i modelli.

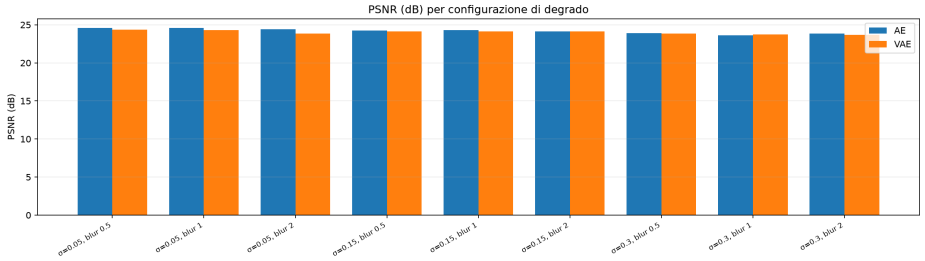
Metriche

Metrica	Cosa misura	Ruolo
MSE	errore quadratico medio	globale
PSNR	$10 \log_{10}(1/\mathrm{MSE})$	dB
SSIM	similarità strutturale	media $\pm$ dev. std
KL	distanza dalla prior gaussiana	solo VAE
Baseline	immagine rumorosa non elaborata	riferimento

Criterio di utilità

Un modello di denoising è utile **solo se batte la baseline rumorosa**: altrimenti conviene lasciare l'immagine così com'è.

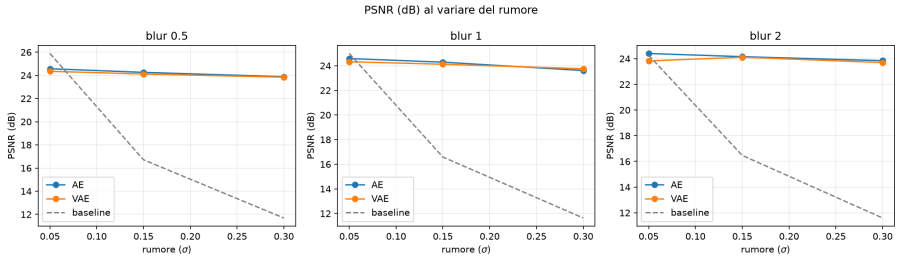
Panoramica dei risultati



PSNR (dB) per le 9 configurazioni; SSIM tra 0,58 e 0,63 per entrambi i modelli.

- PSNR stabile tra 23,61 e 24,58 dB su tutte le configurazioni.
- AE migliore in 8 casi su 9; distacco massimo 0,58 dB.

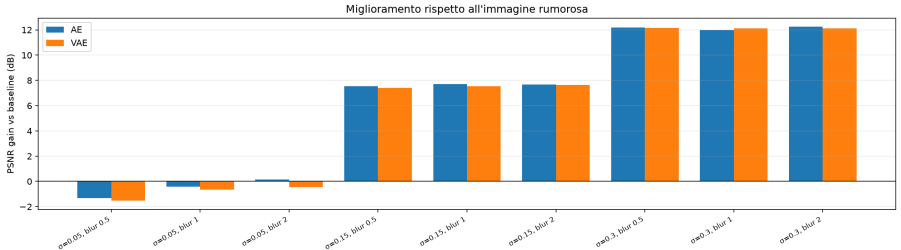
PSNR al variare del rumore



PSNR al crescere del rumore, per i tre livelli di blur.

- Baseline: da 25,89 dB ($\sigma = 0{,}05$) a 11,69 dB ($\sigma = 0{,}30$), blur 0,5.
- Modelli: banda stretta 23,6–24,6 dB, quasi indipendente dal rumore.
- Il vantaggio dei modelli cresce con l'intensità del degrado.

Guadagno rispetto alla baseline



Guadagno di PSNR rispetto all'immagine rumorosa (dB).

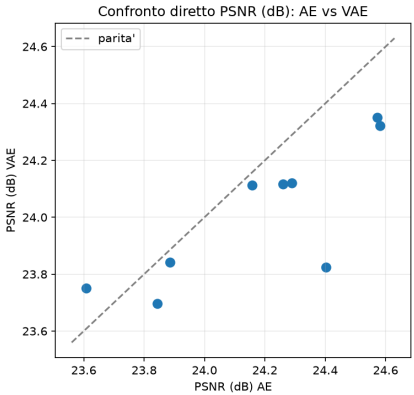
- $\sigma = 0{,}05$: AE $-1{,}31 / -0{,}41 / +0{,}14$ dB, VAE $-1{,}54 / -0{,}67 / -0{,}44$ dB.
- $\sigma = 0{,}15$: circa $+7{,}5$ dB; $\sigma = 0{,}30$: circa $+12$ dB.
- Valori riferiti a blur 0,5 / 1,0 / 2,0.

AE vs VAE

σ	blur 0,5	blur 1,0	blur 2,0
0,05	−0,22	−0,26	−0,58
0,15	−0,14	−0,17	−0,04
0,30	−0,04	+0,14	−0,15

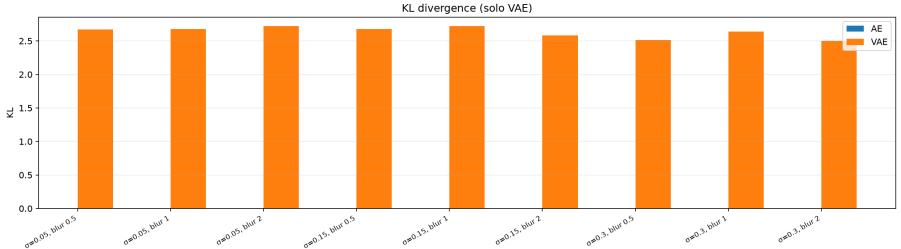
ΔPSNR = VAE − AE (dB)

- AE vince in 8 configurazioni su 9.
- Unico vantaggio VAE: $\sigma = 0{,}30$, blur 1,0 (+0,14 dB).



PSNR VAE vs AE; la diagonale indica la parità.

La KL del VAE



KL del VAE rispetto alla prior gaussiana, per configurazione.

- KL compresa tra 2,50 e 2,72 in tutte le configurazioni.
- $\beta = 10^{-4}$: regolarizzazione attiva ma debole.
- Costo medio di fedeltà del VAE: circa 0,16 dB.

Discussione

- Il denoising conviene solo con rumore sufficientemente forte ($\sigma \geq 0{,}15$).
- A rumore basso il limite è la capacità ricostruttiva ($\sim$24 dB), non il rumore.
- A $\sigma = 0{,}05$ la baseline è già a 25–26 dB: difficile da battere.
- Il VAE paga un piccolo costo di fedeltà per la regolarizzazione latente.
- Il divario AE–VAE si riduce al crescere del rumore.

In sintesi

A parità di budget l'AE è la scelta di default; il VAE ha senso se serve uno spazio latente utilizzabile per generazione o analisi.

Limiti

- 5 epoche di training: modelli probabilmente non saturi.
- Singolo seed: nessuna stima della variabilità.
- Architettura semplice, senza skip connections.
- Solo rumore e blur gaussiani, poco realistici.
- Metriche solo pixel-wise: niente LPIPS, niente analisi per classe.

I limiti non invalidano il confronto, che è a parità di condizioni, ma ne delimitano la portata.

Conclusioni e sviluppi

Conclusioni

- Guadagno fino a $+12$ dB, ma solo con rumore forte.
- AE leggermente preferibile a parità di budget.
- VAE utile se serve uno spazio latente generativo.
- Il tetto è la capacità dell'architettura.

Sviluppi

- Skip connections o architettura U-Net.
- Più epoche e più seed.
- Condizionamento sul livello di rumore.
- FFDNet / DnCNN e metriche percettive.

Il denoising paga quando il degrado supera il limite ricostruttivo del modello.

Grazie

Domande?

Denoising di immagini satellitari EuroSAT: AutoEncoder vs VAE

Alessandro — Ottobre 2026